

8 Feb

Varianza muestral generalizada y Normal multivariada

$$S_n = \frac{1}{n} \sum_j (x_{ji} - \bar{x}_i)$$


$$S = \frac{1}{n-1} \sum_j (x_{ji} - \bar{x}_i) \rightarrow \text{Inseguido}$$

con esta se puede hacer una matriz de varianzas y covarianzas muestral.

¿Qué tan dispersos son nuestros datos en general?


Varianza muestral generalizada = $|S|$ \rightarrow esto es el determinante de la matriz S

mat. de
covs y vars



$|S| = 0 \Leftrightarrow$ hay al menos un vector de desviación que es combinación lineal de los otros.

también si $n \leq p$ $\Rightarrow |S| = 0$.
(deben haber más observaciones que variables)



Varianza generalizada determinada por $|R|$
matriz de coeffs. de correlación.

Si S_{ii} es muy grande (o muy pequeña) geométricamente el vector de desviación correspondiente $d_i = (y_i - \bar{x}_i \mathbf{1}_n)$ será muy largo o muy corto y afectará el volumen.

Para evitar eso es útil escalar todos los valores de desviación para que tengan la misma longitud esto es aplicar a todos los datos originales:

$$x_{ji} = (x_{ji} - \bar{x}_i) / s_{ii}$$

entonces la matriz de varianzas y covarianzas es R :

luego $|R| =$ Varianza muestral generalizada de las variables estandarizadas

También existe la varianza total de la muestra


$$VTM = \sum_i S_{ii}$$

Normal
multivariada

Recordemos: la PDF de una v.a. normal con media μ y var σ^2 es:

$$f_x(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{\frac{-(x-\mu)}{2\sigma^2}}, x \in \mathbb{R}$$

Ley empírica:



• $X \sim N(\mu, \sigma^2)$

• $\frac{(x-\mu)^2}{\sigma^2} \rightarrow$ Distancia estadística entre x y μ
 $= (x-\mu)(\sigma^2)^{-1}(x-\mu)$

Generalizando \vec{x} vector de obs. de X , una fila de la matriz X .

Distancia estadística de \vec{x} a $\vec{\mu}$

$$(\vec{x} - \vec{\mu})' \Sigma^{-1} (\vec{x} - \vec{\mu})$$

entonces podemos generalizar y obtener la pdf de la normal multivariada.

$$f(x) = \frac{1}{(2\pi)^{p/2} \cdot |\Sigma|^{1/2}} \cdot e^{-\frac{(\vec{x} - \vec{\mu})' \Sigma^{-1} (\vec{x} - \vec{\mu})}{2}}$$

Vector aleatorio $\leftarrow x = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} \rightarrow$ v.a.

Denotamos la normal multivariada como:

$$X \sim N_p(\vec{\mu}, \Sigma)$$

Si $p=2$ y $p_{12}=0 = \text{cov}(x_1, x_2) \Rightarrow x_1$ y x_2 indep.

• Si son v.a.s normales y sus correlaciones son cero entonces son indep.

Teorema: Si Σ es def positiva (Σ^{-1} existe)
 entonces si \vec{z} es un vector propio de Σ
 con valor propio asociado λ , \vec{z} es un vector
 propio de Σ^{-1} con val propio asociado $\frac{1}{\lambda}$
 además Σ^{-1} def positiva.

obs: 1) $(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu}) \leq \chi^2_p(\alpha)$
 \downarrow
 gl

Proposición 1) si \vec{X} vector aleatorio normal multivariado
 $\vec{X} \sim N_p(\vec{\mu}, \Sigma)$ entonces

si $\vec{a} \in \mathbb{R}^p$, $\vec{a}^T \vec{X} = \sum a_i X_i$
 $\sim N(\vec{a}^T \vec{\mu}, \vec{a}^T \Sigma \vec{a})$

Prop 2) si $\vec{a}^T \vec{X} \sim N(\vec{a}^T \vec{\mu}, \vec{a}^T \Sigma \vec{a})$, $\forall \vec{a} \in \mathbb{R}^p$
 entonces $\vec{X} \sim N_p(\vec{\mu}, \Sigma)$

Prop 3) $\vec{X} \sim N_p(\vec{\mu}, \Sigma)$ sea $A \in \mathbb{R}^{q \times p}$
 $A \vec{X} \sim N_q(A \vec{\mu}, A \Sigma A^T)$

Prop 4) $\vec{X} \sim N_p(\vec{\mu}, \Sigma)$ $\vec{d} \in \mathbb{R}^p$
 $\vec{X} + \vec{d} \sim N_p(\vec{\mu} + \vec{d}, \Sigma)$

Prop 5) todas las particiones de vectores aleatorios
 Normales resultan en vect. aleatorios
 Normales.

$\vec{X} \sim N_p(\vec{\mu}, \Sigma)$, $\vec{X} = \begin{pmatrix} \vec{X}_{(1)} \\ \vec{X}_{(2)} \end{pmatrix} \begin{matrix} \uparrow q \\ \downarrow p-q \end{matrix}$

$\vec{X}_{(1)} \sim N_q(\vec{\mu}_{(1)}, \Sigma_{11})$ $\vec{\mu} = \begin{pmatrix} \vec{\mu}_{(1)} \\ \vec{\mu}_{(2)} \end{pmatrix}$

$\vec{X}_{(2)} \sim N_{p-q}(\vec{\mu}_{(2)}, \Sigma_{22})$ $\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$

Prop 6) ① Si $X_{(1)}^{q_1 \times 1}$, $X_{(2)}^{q_2 \times 1}$ normales multivariadas e independientes entonces $\text{cov}(X_{(1)}, X_{(2)}) = 0$
 \downarrow $q_1 \times q_2$ matriz

② Si $X = \begin{pmatrix} X_{(1)} \\ X_{(2)} \end{pmatrix} \sim N_{q_1+q_2} \left(\begin{pmatrix} \mu_{(1)} \\ \mu_{(2)} \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right)$

$X_{(1)}$ y $X_{(2)}$ indep si $\Sigma_{12} = 0$

Covarianza cero si implica independencia cuando son Normales

③ $X_{(1)}^{q_1 \times 1}$, $X_{(2)}^{q_2 \times 1}$ normales indep si

$$X = \begin{pmatrix} X_{(1)} \\ X_{(2)} \end{pmatrix} \sim N_{q_1+q_2} \left(\begin{pmatrix} \mu_{(1)} \\ \mu_{(2)} \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} \end{pmatrix} \right)$$

prop 7) sea $X \sim N_p(\vec{\mu}, \Sigma)$, $|\Sigma| > 0$

entonces:

④ $(X - \vec{\mu})' (\Sigma^{-1}) (X - \vec{\mu}) \sim \chi_p^2$

la distancia de los valores a la media tiene distr. χ^2

$$\left\{ (X - \vec{\mu})' (\Sigma^{-1}) (X - \vec{\mu}) \leq \chi_p^2(\alpha) \right\}$$

es $1-\alpha$

Muestreo de la normal multivariada

suponga que $\vec{X}_1, \dots, \vec{X}_n$ son una muestra aleatoria de una población normal multivariada con media $\vec{\mu}$ y cov Σ

Densidad conjunta de $\vec{X}_1, \dots, \vec{X}_n$

$$\prod_{j=1}^n \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} e^{-\frac{1}{2} [(\vec{x}_j - \vec{\mu})' \Sigma^{-1} (\vec{x}_j - \vec{\mu})]}$$

La función de verosimilitud (función de $\vec{\mu}$ y Σ)

dadas las observaciones $x_1, \dots, x_n : \mathcal{L}(\mu, \Sigma)$

Método de máxima verosimilitud:

Utilizar como estimaciones de parámetros poblacionales desconocidos los valores que maximizan $\mathcal{L}(\hat{\mu}, \hat{\Sigma})$ los valores que "mejor" explican los datos.

Teorema: Sean x_1, \dots, x_n una muestra aleatoria de una población normal con media μ y cov. Σ entonces el MLE:

$$\hat{\mu} = \bar{x}, \quad \hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})'$$
$$= S_n = \frac{n-1}{n} S$$

obs: $\hat{\mu}, \hat{\Sigma}$ son vectores Aleatorios hasta el momento en que hay datos.

$$\textcircled{2} \quad \mathcal{L}(\hat{\mu}, \hat{\Sigma}) = \frac{1}{(2\pi)^{\frac{np}{2}}} \cdot e^{-\frac{np}{2}} \times \frac{1}{\underbrace{\left| \hat{\Sigma} \right|^{1/2}}_{\frac{n-1}{n} S}}$$

la varianza generalizada determina el máximo de la función de verosimilitud